TRABALHO DO GRAU B

Modelo conceitual: Processamento de Imagens de Drones

Documento-base do Trabalho do Grau B. Registra o sistema estudado, o modelo implementado pelo grupo, o motivo de cada decisão e os resultados da simulação. A ordem das seções acompanha a apresentação: primeiro o contexto, depois a plataforma, os detalhes do modelo, o experimento e os resultados.

> **Situação:** o modelo está implementado em Python e SimPy na pasta `../simulacao/`, e os dois cenários já foram simulados (seção 5). Falta a animação em MP4 (ver Pontos a verificar).

SEÇÃO 1

Introdução

1.1 Drones na agricultura

Os drones já fazem parte da rotina de muitas operações agrícolas.

> O Brasil tem cerca de **35 mil drones agrícolas**, e o número cresceu **12 vezes** em cinco anos.[1]

Eles são usados de duas formas principais:



Geração de mapas

O drone fotografa a lavoura, e as fotos viram mapas usados para planejar e acompanhar a produção. **É o foco deste estudo.**



Operações de campo

A **pulverização de precisão**, por exemplo, aplica defensivos apenas onde é preciso. *Aparece aqui só como contexto e não é modelada.*

1.2 Exemplos de mapas

Mapa topográfico

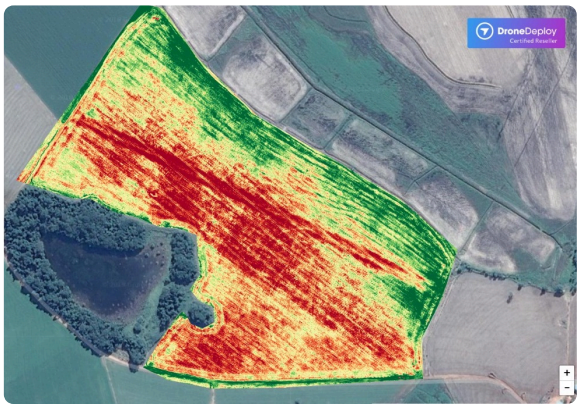
Mostra o relevo do terreno, com a altura de cada ponto. Serve, por exemplo, para dimensionar um sistema de irrigação, já que o relevo determina o caminho da água e a pressão necessária nas tubulações. *Fonte a buscar.*

É esse o tipo de mapa modelado no estudo, formado por ortomosaico e modelo de elevação (ver 2.2).

Mapa NDVI

Um índice de vegetação calculado a partir de câmeras multiespectrais, que ajuda o produtor a estimar o vigor da plantação e a encontrar áreas com problema. *Fonte a buscar.*

Fica fora do escopo do modelo.



Mapa NDVI de um talhão: o vermelho indica vegetação de baixo vigor, e o verde, vegetação vigorosa.



Exemplo do tipo de plataforma estudada: um talhão de 0,48 ha na camada NDVI, com opções de RGB e outros índices (GNDVI, NDRE, LCI e OSAVI). A imagem é ilustrativa: o estudo modela apenas ortomosaico e modelo de elevação.

1.3 Como os mapas são gerados hoje

1

Pela manhã

A equipe de um **prestador de serviço** sai para atender uma fazenda. O cliente quer um mapa atualizado de um **talhão**, uma área delimitada da lavoura, para acompanhar o terreno e a plantação.

2

Em campo

O operador define a área do voo e o drone percorre o talhão em faixas paralelas. Ele fotografa o terreno em intervalos regulares, de modo que cada foto se sobreponha às vizinhas. É essa sobreposição que depois permite montar uma imagem única e reconstruir o relevo. Como referência, um mapeamento de **14 ha levou cerca de 23 minutos** de voo.[2] Ao final, os arquivos ficam no cartão do drone, e a equipe segue para o próximo voo ou para outra fazenda.

3

No fim do dia

A equipe volta à empresa e sobe os arquivos de cada voo em uma **plataforma web**, que processa os dados e monta os mapas.

1.4 Objetivo do trabalho

Modelar e simular essa plataforma web, que recebe os arquivos dos voos e os transforma em mapas, para avaliar se ela entrega os mapas no prazo no período de maior demanda.

SEÇÃO 2

Plataforma de processamento de dados do drone

2.1 Visão do usuário

Para o prestador, o uso é simples: ele sobe os arquivos de cada voo e aguarda. Não precisa instalar software nem manter computadores potentes. Também não precisa acompanhar o processamento: fecha a plataforma e é notificado quando o mapa fica pronto.

Cada voo enviado dá origem a um **mapa**, que é o que a plataforma processa.

Quantidade de imagens por voo

De 20 a 200, com valor mais comum de 80 (ver 4.2).

Tamanho dos arquivos

No mapeamento de 14 ha citado em 1.3, o drone gerou **87 fotos JPG de 11,7 MB cada**, cerca de **1 GB por voo**.[2]

Às vezes falta algo, como fotos que ficaram para trás ao copiar o cartão. Nesse caso, a plataforma avisa o prestador, que envia o que faltou, e o mapa volta a ser conferido.

2.2 Dentro da plataforma

Quando recebe os arquivos, a plataforma começa o tratamento dos dados:

1

Validação

Confere se o prestador enviou todos os arquivos necessários. Essa etapa roda em CPU, antes de ocupar um servidor de processamento.

2

Alinhamento

Identifica pontos em comum entre as fotos sobrepostas e calcula a posição de cada uma. O resultado serve de base para os dois produtos seguintes.

3

Geração dos produtos

Feita em paralelo a partir do alinhamento:

- **Ortomosaico:** as fotos costuradas e corrigidas, formando uma imagem única e sem distorção.
- **Modelo de elevação:** a altura de cada ponto do terreno, que dá o caráter topográfico ao mapa.

4

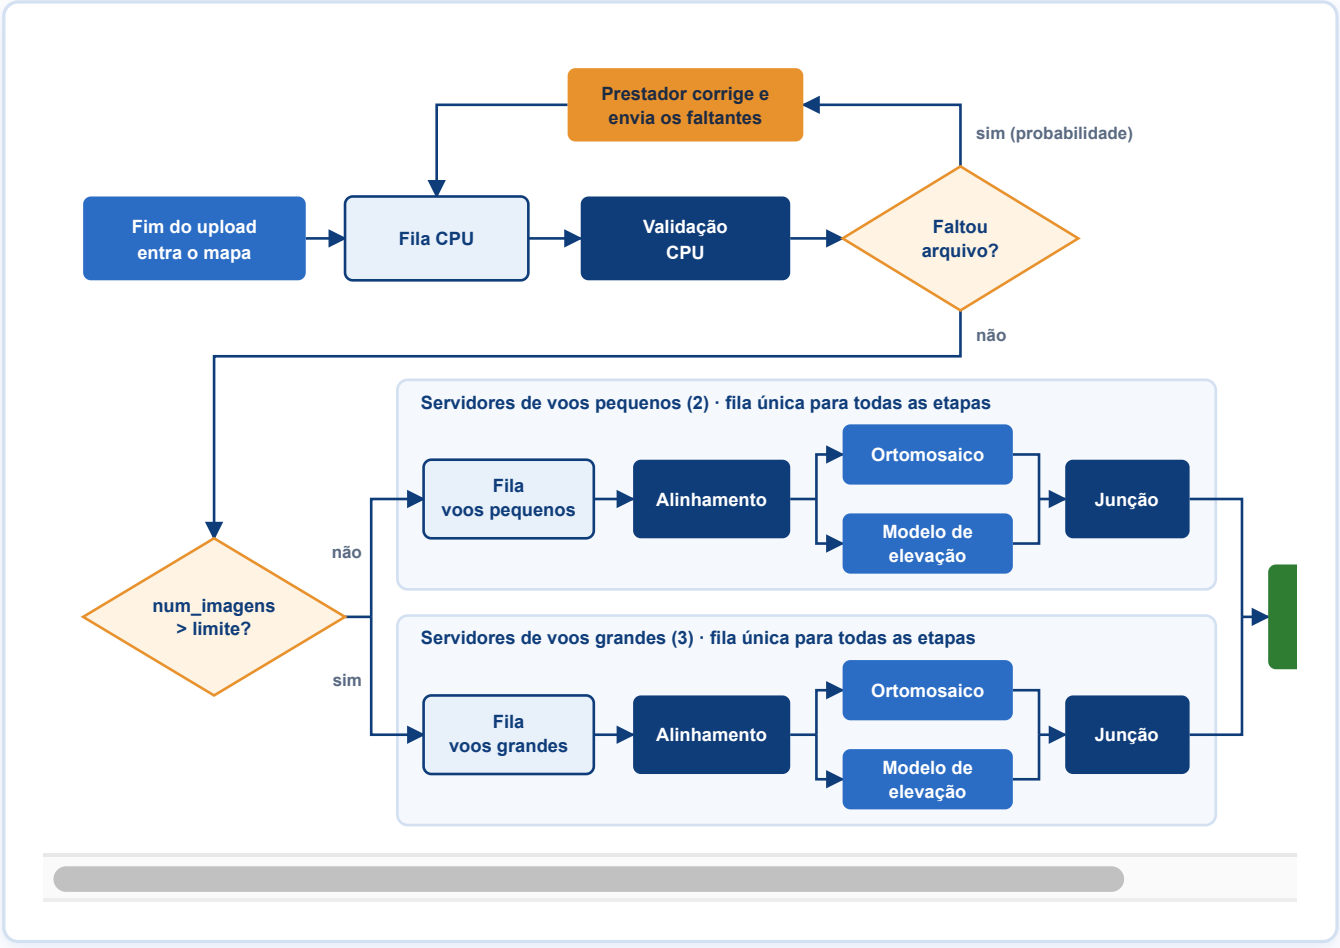
Entrega

Quando os dois produtos terminam, o mapa fica pronto e o prestador é notificado.

O alinhamento e os produtos rodam em **servidores de processamento**, máquinas com GPU dedicadas à fotogrametria. Os servidores são divididos em dois grupos, um para voos pequenos e outro para voos grandes, para que os mapas grandes não bloqueiem os pequenos.

Como referência, o SmartFarm Web processou o ortomosaico e o modelo digital de superfície de um mapa de **12 ha em cerca de 5 minutos**.[3] Esse tempo não inclui o upload das imagens, que também fica fora do modelo.

O fluxograma abaixo mostra esse caminho como ele é representado no modelo:



Legenda do fluxo: *o mapa entra quando termina o primeiro upload e passa pela validação em CPU. Se faltar arquivo, volta à fila da CPU após a correção pelo prestador. Se estiver completo, segue a rota definida pelo número de imagens e usa somente os servidores desse grupo até o fim. Cada grupo tem uma única fila, usada por todas as etapas: depois do alinhamento, ortomosaico e modelo de elevação voltam a essa fila e disputam os servidores com os mapas que ainda vão alinhar. A junção espera os dois produtos, e o mapa segue para a notificação.*

2.3 O problema de gestão

Como as equipes voltam do campo em horários parecidos, os envios se concentram no fim do dia e disputam os mesmos servidores. Formam-se filas justamente no período de maior demanda, e o prestador tem um prazo a cumprir com o cliente.

A plataforma promete o mapa em até **10 minutos**. A gestão precisa saber se a capacidade atual cumpre essa meta no pico ou se vale a pena colocar **mais um servidor em paralelo**.

SEÇÃO 3

Detalhes da modelagem

3.1 Entidades e atributos

Entidade: mapa, que representa o processamento de um voo, do fim do primeiro upload até a notificação.

Atributo	Significado	Uso no modelo
`num_imagens`	Quantidade de imagens do voo	Define a rota e os tempos de processamento
`rota`	Voo pequeno ou voo grande	Define o grupo de servidores
`tentativas`	Número de passagens pela validação	Identifica mapas que precisaram de correção
`instante_entrada`	Fim do primeiro upload	Início do lead time; não muda em caso de reenvio
`instante_saida`	Notificação de mapa pronto	Fim do lead time

3.2 Recursos

Recurso	Capacidade (cenário atual)	Etapas
`CPU`	1	Validação
`Servidores de voos pequenos`	2	Alinhamento e produtos dos mapas até o limite de imagens
`Servidores de voos grandes`	3	Alinhamento e produtos dos mapas acima do limite

Cada servidor é uma máquina com GPU, e todos têm a mesma velocidade. Cada etapa ocupa um servidor e o libera ao terminar. Os dois produtos disputam os servidores de forma independente, então só rodam ao mesmo tempo se houver dois livres.

O prestador não é um recurso: a correção é um atraso sem fila, porque cada um corrige o próprio envio.

3.3 Filas

`Fila CPU`, `Fila voos pequenos` e `Fila voos grandes`, todas FIFO e sem limite de buffer. Nenhum mapa é descartado ou desiste.

Cada grupo de servidores tem uma única fila, compartilhada por alinhamento, ortomosaico e modelo de elevação. Um mapa entra nela três vezes, uma por tarefa, e o servidor que fica livre pega a tarefa mais antiga, sem distinguir o tipo.

3.4 Regras de fluxo

Decisão por probabilidade

Na validação, cada tentativa tem a mesma chance de detectar arquivos faltando. O mapa repete a validação até passar.

Reenvio

O prestador envia só os arquivos faltantes, o que não altera `num_imagens`. O relógio do lead time continua correndo.

Decisão por condição

Mapas com `num_imagens` acima do limite vão para os servidores de voos grandes; os demais, para os de voos pequenos.

Fluxo paralelo

Após o alinhamento, o mapa se duplica em ortomosaico e modelo de elevação. A junção espera os dois, e o mapa sai quando o último termina.

3.5 Indicadores

1

P90 do lead time (indicador principal)

Em minutos, medido do fim do primeiro upload até a notificação de mapa pronto, incluída a correção pelo prestador, com meta de até 10 min. É calculado por noite simulada, e o IC de 95% é obtido entre as replicações.

2

Mapas fora do prazo

Em mapas por noite, medidos do fim do primeiro upload até a notificação de mapa pronto, contando aqueles com lead time acima de 10 min, com meta de até 10% dos mapas da noite. *O percentual é uma proposta a confirmar.*

Complementares: lead time médio (min), vazão (mapas/h) e utilização de cada grupo de servidores (%).

3.6 Implementação

O modelo está em `../simulacao/`, em scripts Python que rodam localmente. Os parâmetros ficam como constantes no topo de `modelo.py`, com os mesmos valores da seção 4.2.

Elemento do modelo	Onde está no código (`modelo.py`)
Entidade mapa e seus atributos	classe `Mapa` (`num_imagens`, `rota`, `tentativas`, `instante_entrada`, `instante_saida`)
Chegadas da noite	`gerar_mapas` sorteia a quantidade (Poisson), os horários (Triangular) e `num_imagens`; `chegadas` libera cada mapa no seu horário
Validação e reenvio	laço em `processar_mapa`: CPU (`simpy.Resource`), sorteio da falta de arquivos e atraso da correção
Rota por `num_imagens`	definida em `gerar_mapas` (`num_imagens > LIMITE_ROTA`)
Servidores e filas	um `simpy.Resource` por grupo, com fila FIFO única para as três etapas
Alinhamento, produtos em paralelo e junção	`tarefa_servidor`; os dois produtos são processos SimPy separados, e a junção é `ortomosaico & elevacao`

Elemento do modelo	Onde está no código (`modelo.py`)
Monitor para gráficos e animação	`monitor` amostra filas, servidores ocupados e mapas concluídos a cada 0,5 min
Indicadores	`calcular_metricas`

Os outros scripts usam esse módulo: `executar_cenarios.py` roda as 30 replicações por cenário e calcula os IC; `graficos.py` gera os gráficos da seção 5.3. Para rodar, a partir de `grau-b/simulacao/`: `../../.venv/bin/python executar_cenarios.py` e `../../.venv/bin/python graficos.py`.

Cada mapa tem um gerador aleatório próprio, derivado da semente da replicação e do seu número. Assim, a replicação *i* tem os mesmos mapas e os mesmos tempos nos dois cenários (números aleatórios comuns), e a diferença entre eles vem só da capacidade.

SEÇÃO 4

Experimento e premissas

4.1 Chegadas e horizonte

Os envios se concentram no fim do dia, com pico entre 17h e 21h. Cada replicação simula uma noite de pico, com relógio em minutos, e termina quando o último mapa fica pronto. Por isso, é uma simulação terminante.

4.2 Distribuições de entrada

Os tempos de processamento vêm de um benchmark publicado.[4] Validação, falta de arquivos e correção ainda não têm fonte.

Grandeza	Distribuição	Parâmetros	Unidade	Justificativa
Mapas por noite	Poisson	média 100	mapas/noite	Dimensionada para que os servidores de voos grandes fiquem perto de 90% de ocupação no pico do cenário atual
Horário de envio	Triangular	mín 17h, moda 18h30, máx 21h	hora	Retorno concentrado das equipes no fim do dia, com pico às 18h30
`num_imagens`	Triangular	mín 20, moda 80, máx 200	imagens	Exemplo real: 14 ha geraram 87 imagens [2], perto da moda
Limite da rota	Constante	80	imagens	Igual à moda: cerca de 1/3 dos mapas vai para os servidores de voos pequenos
Tempo de validação	Uniform	mín 5, máx 15	s	*A preencher*
Falta de arquivos	Bernoulli	5% por tentativa	probabilidade	*A preencher*
Tempo de correção	Uniform	mín 1, máx 3	min	*A preencher*

Grandeza	Distribuição	Parâmetros	Unidade	Justificativa
Alinhamento	Uniform	mín 0,69, máx 1,03	s/imagem	Etapa *calibration* do PIX4Dmatic: 86 s para 100 imagens, ou 0,86 s/imagem [4]; variação de ±20% assumida
Modelo de elevação	Uniform	mín 1,22, máx 1,84	s/imagem	Etapas *dense point cloud* e *DSM*: 115 s + 38 s para 100 imagens, ou 1,53 s/imagem [4]; variação de ±20% assumida
Ortomosaico	Uniform	mín 0,15, máx 0,23	s/imagem	Etapa *orthomosaic*: 19 s para 100 imagens, ou 0,19 s/imagem [4]; variação de ±20% assumida

Em cada etapa de processamento, o tempo é `num_imagens` × tempo por imagem sorteado. Os dois grupos de servidores têm a mesma velocidade.

Conferência com a plataforma real: com esses tempos, um mapa de 12 ha (cerca de 75 imagens, a 6 imagens/ha[2]) leva cerca de 3 min sem fila: 64 s de alinhamento e 115 s de modelo de elevação. O SmartFarm Web levou cerca de 5 min para o mesmo tamanho.[3] A ordem de grandeza bate, e a diferença cabe no overhead da nuvem.

4.3 Cenários

Cenário	Servidores de voos pequenos	Servidores de voos grandes	Demanda	Replicações
Atual	2	3	Pico	≥ 30
Servidor extra	2	4	Pico	≥ 30

O servidor extra vai para o grupo de voos grandes, que é o gargalo. Pela conta manual no instante de maior demanda (cerca de 50 mapas/h), esse grupo fica perto de 96% de ocupação no cenário atual e de 72% com o servidor extra. O grupo de voos pequenos fica perto de 36%.

A comparação usa o IC de 95% do P90 do lead time. Intervalos que não se sobrepõem indicam diferença conclusiva; intervalos sobrepostos não permitem concluir pela diferença.

4.4 Questões do estudo

1. Na situação atual, o **P90 do lead time** atende à meta de 10 min no pico?
2. Um servidor a mais em paralelo **reduz o P90 do lead time** com IC sem sobreposição? Em quantos minutos?
3. Quantos mapas por noite **deixam de ficar fora do prazo** com o servidor extra?

4.5 Classificação do sistema

Dinâmico

O estado muda ao longo da noite, com filas que crescem no pico e depois se esvaziam.

Estocástico

Chegadas, quantidades de imagens por mapa, tempos de serviço e falta de arquivos são aleatórios.

Discreto

O estado muda em instantes definidos, como chegadas e conclusões de etapas.

4.6 Hipóteses e simplificações

- **Voos de até 200 imagens:** com cerca de 2,4 s por imagem entre alinhamento e modelo de elevação,[4] um mapa de 200 imagens leva cerca de 8 min sem fila, dentro da meta de 10 min. Voos maiores ficam fora do escopo.
- **Tempos proporcionais:** os tempos de processamento crescem na proporção do número de imagens.
- **Servidores iguais:** todos têm a mesma velocidade, porque a GPU muda pouco o tempo total.[4] [5]
- **Ortomosaico em paralelo:** no PIX4Dmatic, o ortomosaico é gerado depois do modelo de superfície.[4] O modelo trata os dois em paralelo. Como o ortomosaico é curto (0,19 s/imagem), o efeito no lead time é pequeno.
- **Upload fora do modelo:** o relógio começa no fim do primeiro upload. O envio dos faltantes faz parte do tempo de correção.
- **Prestador sempre corrige:** não há desistência, e a correção não depende de quantos arquivos faltaram.
- **Sem falhas técnicas:** os servidores não param, e o alinhamento e a geração dos produtos sempre dão certo.
- **Mapas de índices fora do escopo:** a plataforma do exemplo também exibe índices como o NDVI, mas o estudo modela apenas ortomosaico e modelo de elevação.
- **Apenas a noite de pico:** os resultados não se aplicam a períodos de demanda normal.

SEÇÃO 5

Resultados da simulação

Os resultados foram gerados pelo programa em `../simulacao/`, com 30 replicações por cenário. Os dois cenários usam números aleatórios comuns: a replicação *i* tem os mesmos mapas e os mesmos tempos sorteados nos dois cenários, e só muda o número de servidores.

5.1 Indicadores por cenário

Média das 30 noites, com IC de 95% (t de Student).

Indicador	Atual (2 + 3 servidores)	Servidor extra (2 + 4 servidores)	Meta
P90 do lead time	**9,47 min**, IC [8,74; 10,20]	**7,10 min**, IC [6,89; 7,32]	até 10 min

Indicador	Atual (2 + 3 servidores)	Servidor extra (2 + 4 servidores)	Meta
Mapas fora do prazo	**8,3 mapas/noite**, IC [5,7; 10,9]	**0,7 mapas/noite**, IC [0,1; 1,2]	—
Mapas fora do prazo (%)	8,5%, IC [5,9; 11,0]	0,7%, IC [0,1; 1,2]	até 10%
Lead time médio	5,37 min, IC [5,12; 5,61]	4,57 min, IC [4,46; 4,68]	—
Vazão	25,5 mapas/h	25,5 mapas/h	—
Utilização, voos grandes (noite inteira)	47,5%	35,6%	—
Utilização, voos pequenos (noite inteira)	19,5%	19,5%	—

"2 + 3 servidores" significa 2 servidores de voos pequenos e 3 de voos grandes. A vazão é igual nos dois cenários porque todos os mapas terminam e a noite acaba quase na mesma hora; por isso ela não serve para comparar os cenários.

5.2 Respostas às questões do estudo

1

O cenário atual atende à meta?

Não é possível afirmar. O P90 médio é de 9,47 min, mas o IC [8,74; 10,20] contém a meta de 10 min. Na prática, o cenário atual opera no limite.

2

Um servidor a mais reduz o P90?

Sim. O P90 cai **2,37 min**, de 9,47 para 7,10 min, e os intervalos não se sobrepõem: a diferença é conclusiva. Com o servidor extra, o IC inteiro fica abaixo da meta.

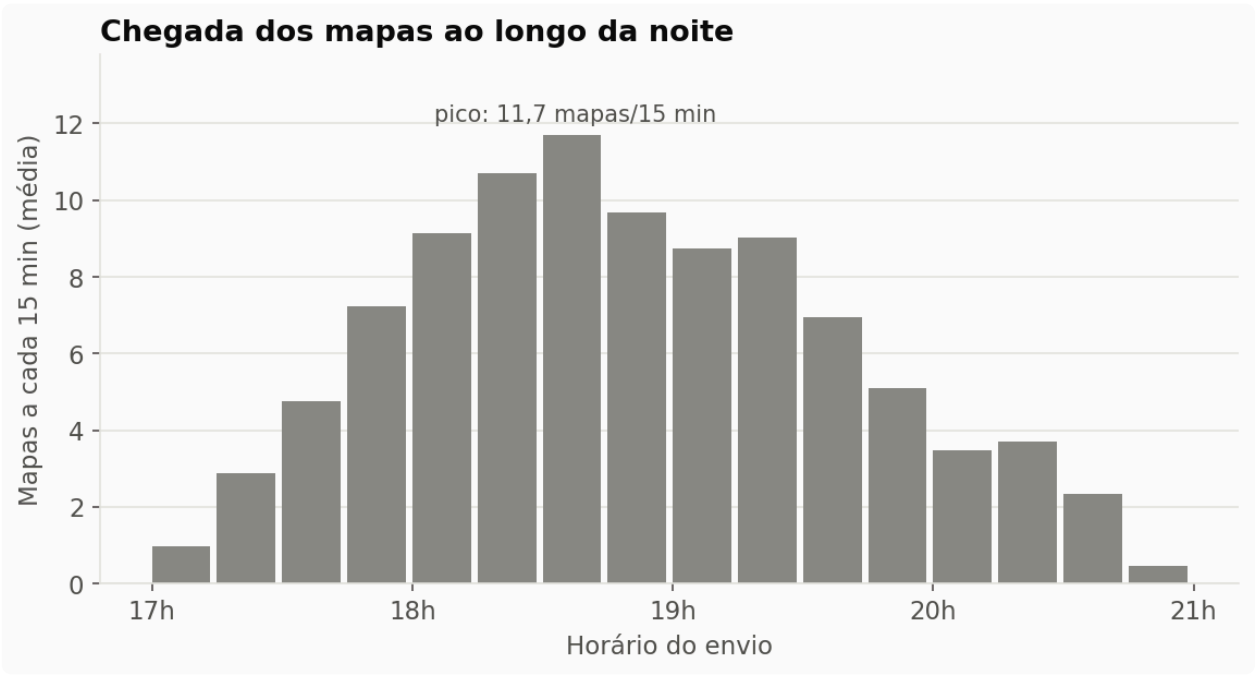
3

Quantos mapas saem do atraso?

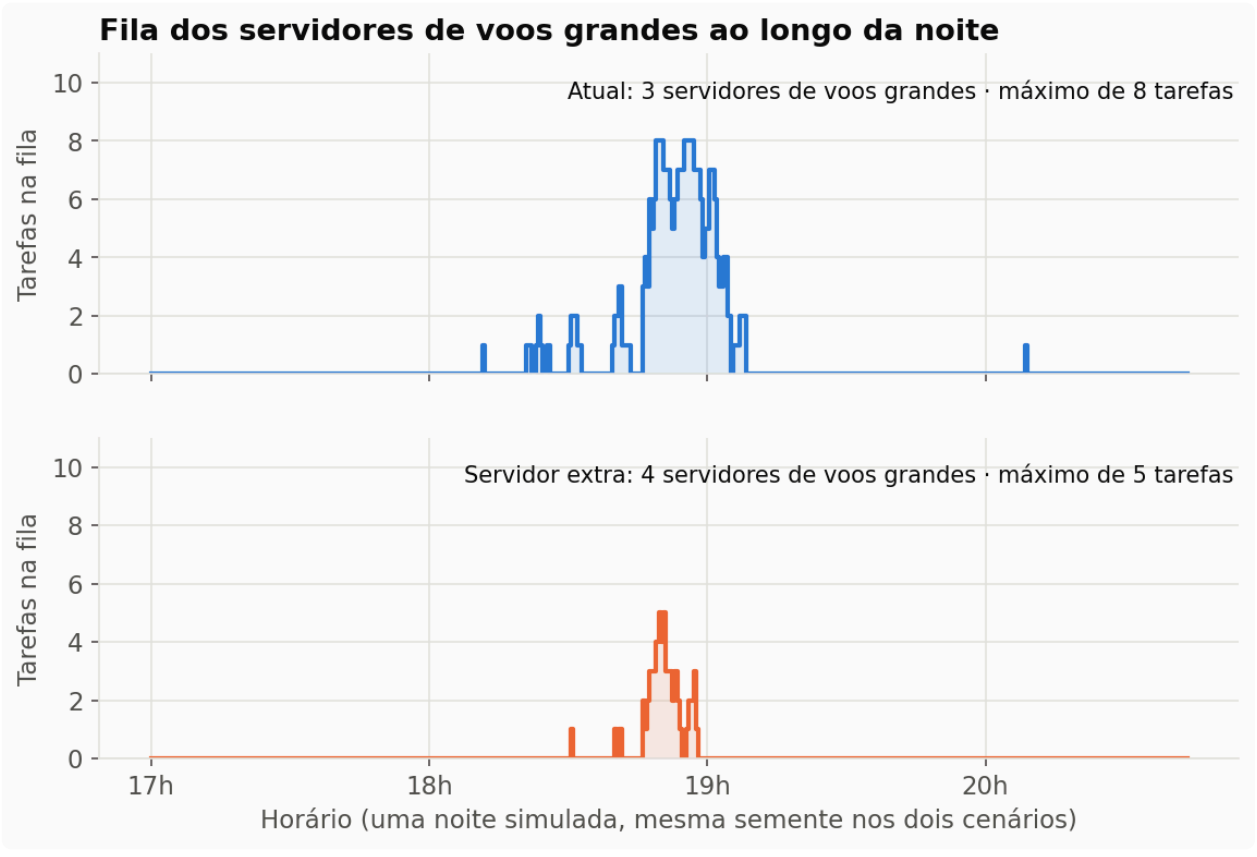
Cerca de **7,7 mapas por noite**, de 8,3 para 0,7. Dentro da meta, a proporção de mapas sobe de 91,4% para 99,3%.

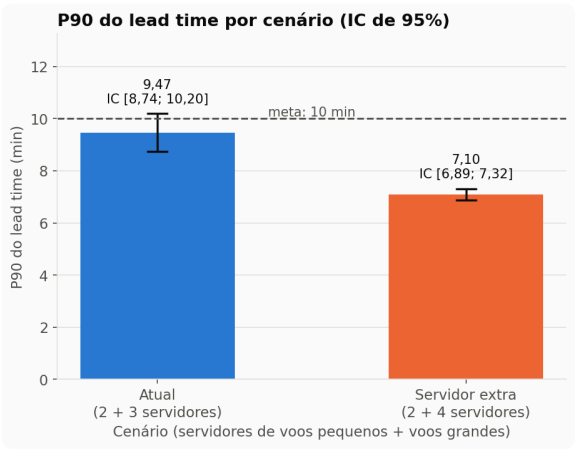
5.3 Gráficos

Chegada dos mapas. Os envios crescem a partir das 17h, chegam ao pico entre 18h30 e 18h45 (cerca de 12 mapas a cada 15 min) e caem até as 21h. Esse pico é o que forma a fila.

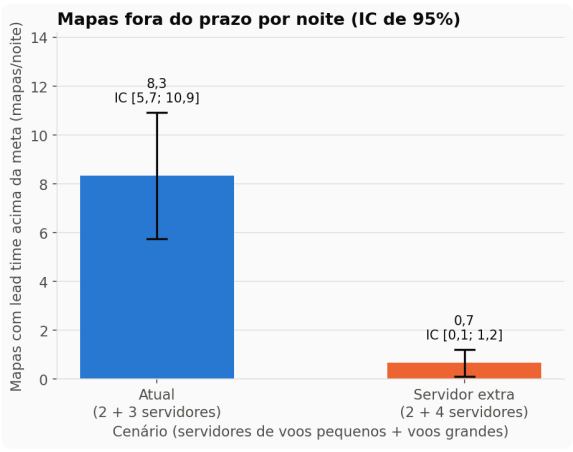


Fila dos servidores de voos grandes, em degraus. Uma noite simulada, com os mesmos mapas nos dois cenários. A fila conta tarefas, e cada mapa entra nela três vezes (alinhamento, ortomosaico e elevação). No cenário atual, a fila chega a 8 tarefas entre 18h45 e 19h05; com o servidor extra, a mesma onda chega a 5 e esvazia mais rápido. No resto da noite, a fila fica praticamente vazia nos dois cenários.



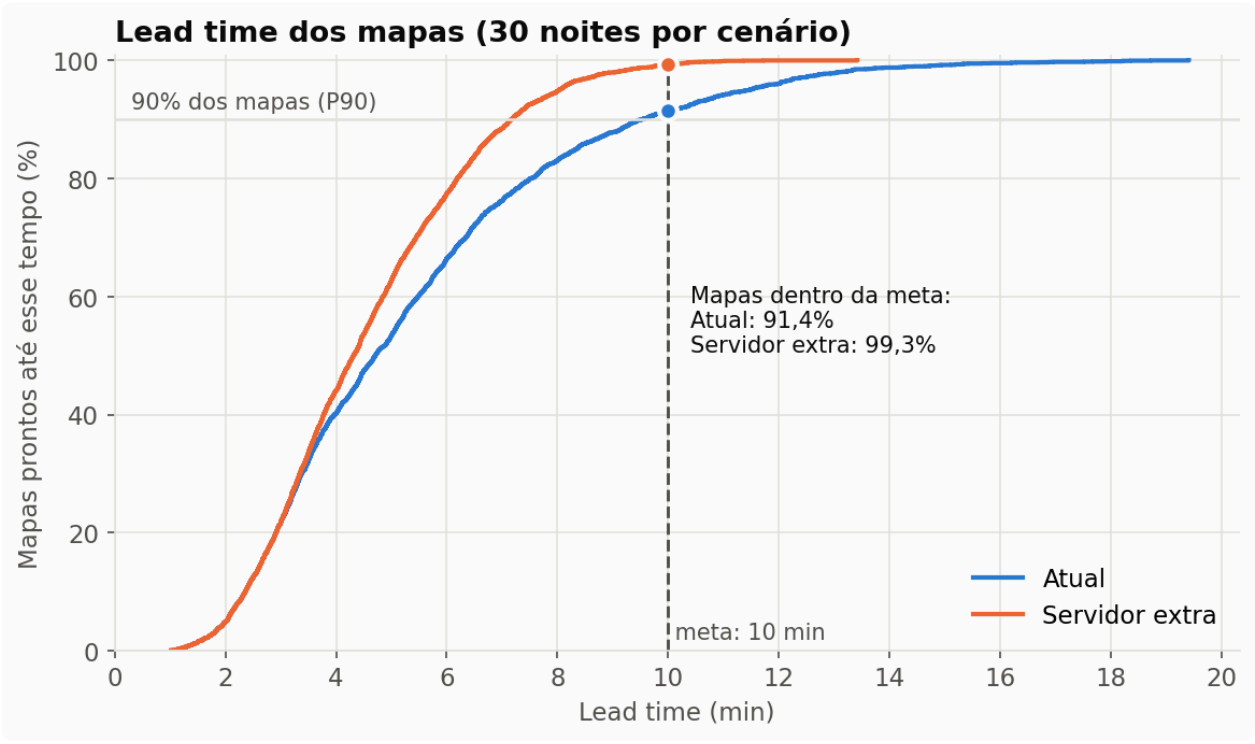


P90 do lead time por cenário, com IC em barras de erro: o gráfico de comparação do indicador principal.

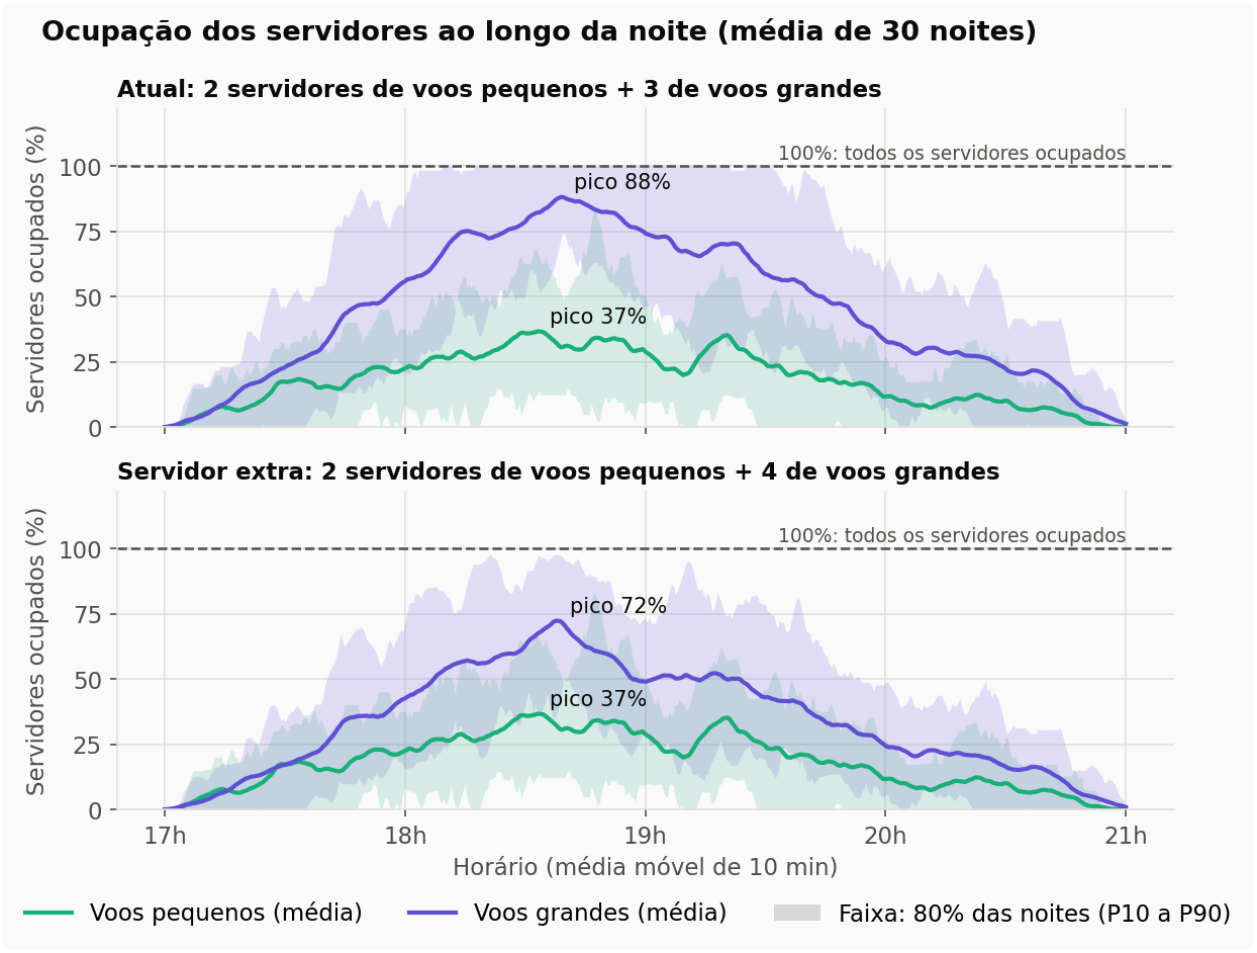


Mapas fora do prazo por noite, com IC. O IC do cenário atual é largo porque algumas noites têm um pico mais forte que outras.

Distribuição do lead time. Proporção de mapas prontos até cada tempo, juntando as 30 noites. Até cerca de 3,5 min as curvas coincidem: esses mapas são processados sem fila. Depois, o cenário atual tem uma cauda longa, com mapas de até cerca de 19 min; com o servidor extra, todos terminam em menos de 14 min. O servidor extra quase não muda o mapa típico, mas corta a cauda do pico, que é o que o P90 mede.



Ocupação dos servidores ao longo da noite. A linha é a média das 30 noites, e a faixa sombreada cobre 80% das noites (do percentil 10 ao 90). No cenário atual, os servidores de voos grandes chegam a 88% de ocupação média por volta das 18h40, e a borda de cima da faixa encosta em 100% entre cerca de 18h e 19h40. Às 18h40, 27 das 30 noites estavam com os 3 servidores ocupados. A média fica abaixo de 100% porque o pico não acontece na mesma hora em todas as noites (de 17h59 a 19h19) e porque a curva é suavizada. Com o servidor extra, o pico médio cai para 72%, e a faixa raramente chega a 100%. Os servidores de voos pequenos não passam de 37% em média nos dois cenários.



5.4 Conclusões e recomendações

O gargalo está nos servidores de voos grandes

Como previa a conta manual: 88% de ocupação média no pico, contra 37% nos de voos pequenos.

O cenário atual opera no limite da meta

P90 de 9,47 min, com IC que contém os 10 min, e cerca de 8,3 mapas por noite fora do prazo.

Recomendação: um servidor de voos grandes a mais

O P90 cai 2,37 min, para 7,10 min, com IC inteiro abaixo da meta, e os mapas fora do prazo caem de 8,3 para 0,7 por noite.

O ganho se concentra no pico

Antes das 17h45 e depois das 20h, os dois grupos ficam abaixo de 50% de ocupação média. Se a plataforma roda na nuvem, um servidor a mais só no horário de pico pode dar ganho parecido com custo menor. *O modelo atual não testa essa alternativa.*

SEÇÃO 6 · CONTROLE DO TRABALHO

Atendimento aos requisitos do enunciado (seção 3)

Item	Requisito	Solução no modelo
a	Base do estudo	Este documento; justificativas das distribuições parcialmente pendentes
b	Decisões	Probabilidade: falta de arquivos. Condição: rota por `num_imagens`
c	Indicadores	Mapas fora do prazo (contagem) e P90 do lead time
d	Atributo com significado	`num_imagens`, usado na rota e nos tempos
e	Lotes ou duplicações	Ortomosaico e modelo de elevação em paralelo, com junção
f	Demonstração visual	Monitor implementado (amostras a cada 0,5 min). **Falta** a animação em MP4, com título do cenário, relógio, ao menos três indicadores com unidade e um gráfico com eixos rotulados
g	Gráficos de resultados	Gerados (seção 5.3): fila de voos grandes em degraus; P90 do lead time por cenário, com IC em barras de erro
h	Experimentação	Feito: dois cenários, 30 replicações cada e IC de 95% do P90 (seção 5.1)
i	Análise	Feito: conclusões e recomendações com número, unidade e comparação (seção 5.4)

POR QUE ASSIM

Registro de decisões

Decisão	Por quê	Alternativas descartadas
Python + SimPy	Ferramenta aceita pela disciplina e já usada no Grau A	JaamSim, Arena
Scripts Python locais em vez de caderno	Mais fácil de rodar, versionar e dividir entre os integrantes	Caderno Jupyter (pode ser gerado no fim, se o enunciado exigir)
Números aleatórios comuns entre os cenários	A replicação *i* simula a mesma noite nos dois cenários, o que reduz a variância da comparação	Sementes independentes por cenário
Usuário: prestador de serviço	Envia vários voos e tem prazos a cumprir com clientes, o que dá sentido à meta	Produtor rural; os dois perfis
Upload ao fim do voo, chegando à plataforma no fim do dia	A equipe termina o campo, volta à empresa e sobe os arquivos, o que concentra a demanda	Envio imagem a imagem; upload no campo com falhas
Prestador sai e é notificado	Corresponde ao uso esperado e mantém o lead time como foco	Cancelar na fila; reenviar por demora
Falha na validação, por falta de arquivos	É um erro do prestador, detectado antes de ocupar um servidor	Falha no alinhamento; falha maior em mapas grandes; limite de reenvios
Reenvio só dos faltantes, repetindo até dar certo	Todo mapa termina, e o lead time fica definido para todos	Reenviar o voo inteiro

Decisão	Por quê	Alternativas descartadas
Lead time desde o primeiro envio	Mostra a espera real e segue a definição do enunciado	Contar cada envio separadamente
Rota por `num_imagens`	É uma decisão condicional natural, dá uso direto ao atributo e impede que mapas grandes bloqueiem os pequenos	Rejeição por qualidade; prioridade por prazo
Ortomosaico + modelo de elevação em paralelo	Tarefas paralelas a partir do alinhamento, sem exigir câmera multiespectral. Na prática o ortomosaico depende da superfície, mas é curto	Mapa de índices; blocos de imagens; voos em lote
Servidores de processamento, todos com a mesma velocidade	Benchmark mostra 5% a 9% de diferença entre GPUs [4]; a GPU acelera só o alinhamento [5]	Velocidades diferentes por grupo de servidores
Tempos por imagem do benchmark da Puget Systems	É a fonte mais recente encontrada com tempo por etapa, em 100 imagens, perto da nossa moda	OpenDroneMap, cerca de 10 vezes mais lento [6]; comparações entre softwares com resultados contraditórios
Fila única FIFO por grupo de servidores	É a regra mais simples de implementar e explicar. Em troca, mapas já alinhados podem esperar atrás de novos mapas	Prioridade para os produtos; servidores separados por etapa
Comparar atual e um servidor extra no pico	Responde à decisão de investimento: mais capacidade em paralelo no grupo que é o gargalo	Atual, +1 e +2 servidores; dobrar os servidores
Meta de 10 min	Com os tempos do benchmark, um mapa de 200 imagens leva cerca de 8 min sem fila; com 5 min, o P90 nunca atingiria a meta	5 min (inviável com os tempos reais); 5 min com voos de até 120 imagens
Demanda de 100 mapas por noite	Deixa o cenário atual perto de 90% de ocupação no pico com poucos servidores, o que mantém a animação legível	250 mapas por noite, com cerca de 9 servidores
Chegadas Triangular(17h, 18h30, 21h)	Representam o retorno concentrado das equipes e fazem a fila crescer	Poisson em janela fixa; pulsos por empresa
Contagem: mapas fora do prazo	Reage ao servidor extra e ajuda a comparar os cenários	Mapas reenviados; mapas concluídos
Ordem do documento segue a apresentação	Contexto agrícola, plataforma e só então o modelo, o que facilita a leitura por quem não acompanhou as decisões	Ordem "sistema → modelo"

PENDÊNCIAS

Pontos a verificar

- [ ] **Valores sem fonte:** validação, falta de arquivos e correção.

- [ ] **Variação dos tempos:** o benchmark dá um valor por etapa; a variação de ±20% é uma suposição do grupo.
- [ ] **Meta de mapas fora do prazo:** confirmar o limite de 10% e definir o valor absoluto.
- [ ] **Formato do entregável:** o enunciado pede o modelo em caderno. Confirmar com o professor se os scripts são aceitos ou gerar um `.ipynb` que chame os scripts.
- [ ] **Fontes da introdução:** buscar referências para o uso de mapas topográficos no dimensionamento de irrigação e para o NDVI.

Já confirmados na simulação (seção 5): o gargalo está nos servidores de voos grandes; o cenário atual fica perto da meta, e a comparação mostra diferença conclusiva; os reenvios não determinam o P90 (sem os mapas com reenvio, 5,2% do total, o P90 do cenário atual cai só de 9,47 para 9,33 min).

CONTINUAÇÃO

Próximos passos

Feito: modelo em SimPy, 30 replicações por cenário com IC, gráficos de resultados, conclusões e recomendações (seção 3.6 e seção 5).

A fazer:

1. Gerar a animação em MP4 com `FuncAnimation`, a partir das amostras do monitor (requisito f).
2. Buscar fontes para os tempos de validação, a falta de arquivos e o tempo de correção.
3. Confirmar o formato do entregável do modelo (scripts ou caderno).
4. Obter no Moodle o template do relatório e confirmar a data de entrega.
5. Escrever o relatório, com a declaração de uso de IA, e preparar os slides com o vídeo.

FONTES

Referências

1. VALOR ECONÔMICO. Número de drones cresceu 12 vezes em cinco anos. *Valor Econômico*, especial Agronegócio, 27 abr. 2026. Disponível em: valor.globo.com. Usada para: cerca de 35 mil drones agrícolas no Brasil (seção 1.1).
2. WDDRONES. Tutorial completo DJI SmartFarm Web (2025). *YouTube*, 2025. Disponível em: youtube.com/watch?v=7vQuAK239-k. Usada para: mapeamento de 14 ha em cerca de 23 minutos de voo (seção 1.3), com 87 fotos JPG de 11,7 MB cada (seções 2.1 e 4.2).
3. AMERICA AGRICOLA. Como gerar ortomosaico e modelo digital de superfície no SmartFarm Web | DJI | Victor Agostinho. *YouTube*. Disponível em: youtube.com/watch?v=44Iz9D4oGvk. Usada para: processamento de 12 ha em cerca de 5 minutos, aos 10:12 do vídeo (seções 2.2 e 4.2).
4. LAGERGREN, Evan. Exploring PIX4Dmatic hardware performance. *Puget Systems*, 26 nov. 2025. Disponível em: pugetsystems.com. Usada para: tempos por etapa com 100 imagens na RTX 5080 (calibration 86 s, dense point cloud 115 s, DSM 38 s, orthomosaic 19 s) e diferença de 5% a 9% entre GPUs (seções 2.3, 4.2 e 4.6).
5. PIX4D. Hardware and computer setup. *Pix4D Support*. Disponível em: support.pix4d.com. Usada para: a CPU pesa mais que a GPU no tempo total, e a GPU reduz só o alinhamento, em 10% a 20% (seções 2.3 e 4.6).

6. FERREIRA, Carlos Y. M. et al. Edge computing in photogrammetry: performance and trade-offs of OpenDroneMap on NVIDIA Jetson Nano. In: ESCOLA REGIONAL DE ALTO DESEMPENHO DA REGIÃO NORDESTE (ERAD-NE), 7., 2026, Recife. *Anais* [...]. Porto Alegre: SBC, 2026. p. 29-32. DOI: 10.5753/erad-ne.2026.26672. Usada para: no OpenDroneMap, 46 imagens levaram 19 min 50 s em desktop, cerca de 26 s/imagem, com a GPU abaixo de 2% de uso (registro de decisões).